Vectorización de textos

Aprendizaje Automático y PLN

El Aprendizaje Automático es esencial en el PLN para tareas como:

- Traducción automática
- Análisis de sentimientos
- Resumen de texto
- Q/A
- Extracción de entidades

Aprendizaje supervisado

El aprendizaje supervisado es un enfoque del aprendizaje automático en el que el modelo se entrena en un conjunto de datos etiquetados, es decir, datos que tienen una respuesta o salida conocida.

Ejemplo: Clasificación de correos electrónicos como spam o no spam en función de ejemplos previamente etiquetados

Flujo de trabajo

Proceso de aprendizaje supervisado:

1. Estructurar dataset inicial
2. **Extraer descriptores**
3. Partir dataset en dos (o tres) partes
4. Entrenar/construir un modelo de predicción
5. Evaluar el modelo

Flujo de trabajo

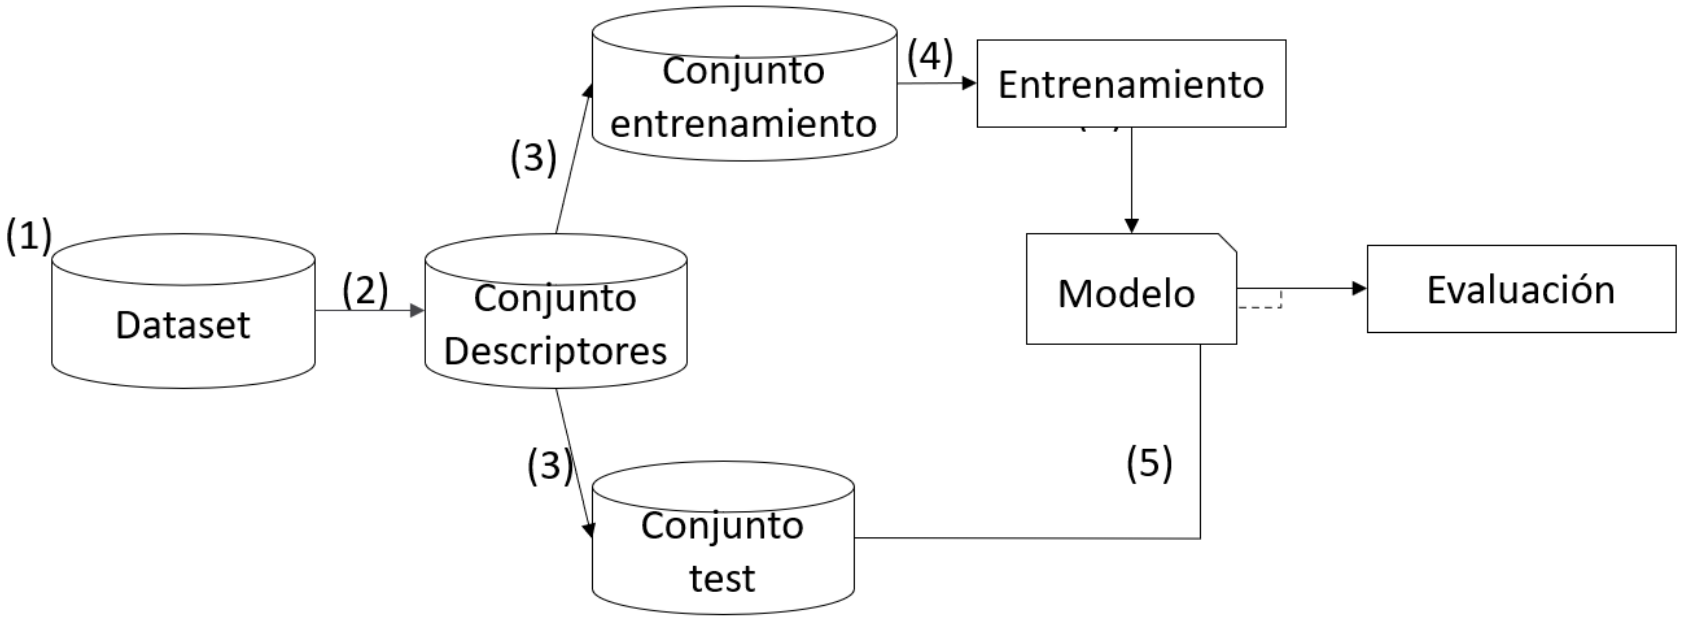

Vectorización de textos

Índice

REPRESENTACIÓN DE TEXTOS

USO EN MODELOS DE APRENDIZAJE AUTOMÁTICO

Representación de texto

Modelos de aprendizaje trabajan con vectores de números

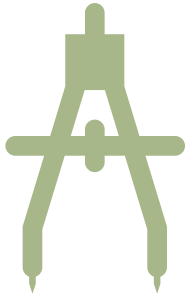

Vectorización: proceso de convertir texto a vectores numéricos

Vectorización

Segmentar texto en palabras, y transformar cada palabra en un vector

Segmentar texto en caracteres, y transformar cada carácter en un vector

Extraer n-gramas de palabras o caracteres, y transformar cada n-grama en un vector

Vectorización

La inteligencia artificial está transformando muchas industrias.

Bi-gramas (2-gramas):
- "La inteligencia"
- "inteligencia artificial"
- "artificial está"
- "está transformando"
- "transformando muchas"
- "muchas industrias"

Tri-gramas (3-gramas):
- "La inteligencia artificial"
- "inteligencia artificial está"
- "artificial está transformando"
- "está transformando muchas"
- "transformando muchas industrias"

Vectorización

Inteligencia

Bi-gramas (2-gramas):
- "in"
- "nt"
- "te"
- "el"
- "li"
- "ig"
- "ge"
- "en"
- "nc"
- "ci"
- "ia"

Tri-gramas (3-gramas):
- "int"
- "nte"
- "tel"
- "eli"
- "lig"
- "ige"
- "gen"
- "enc"
- "nci"
- "cia"

Tokenización

Proceso de partir texto en tokens (o elementos):

- Palabras
- Caracteres
- N gramas

Tokenización

- Hay un león corriendo

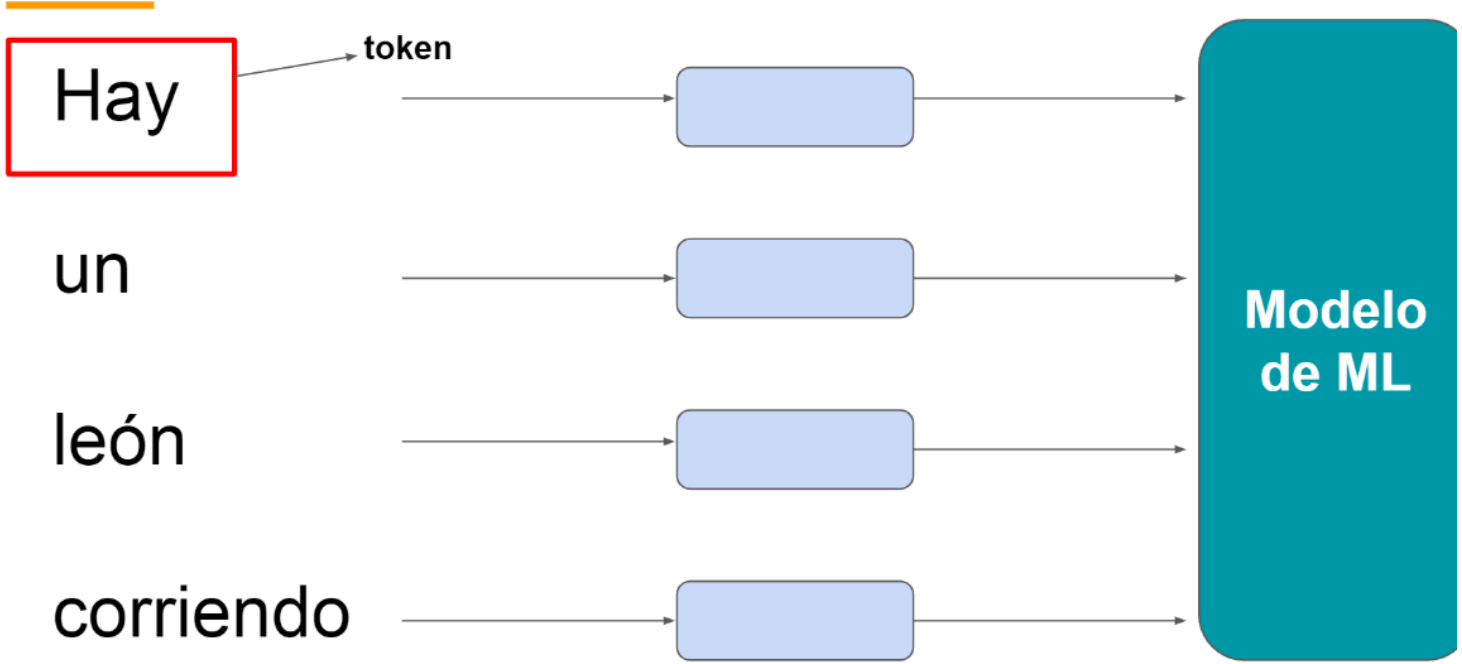
Hay
un
león
corriendo
token
Modelo de ML

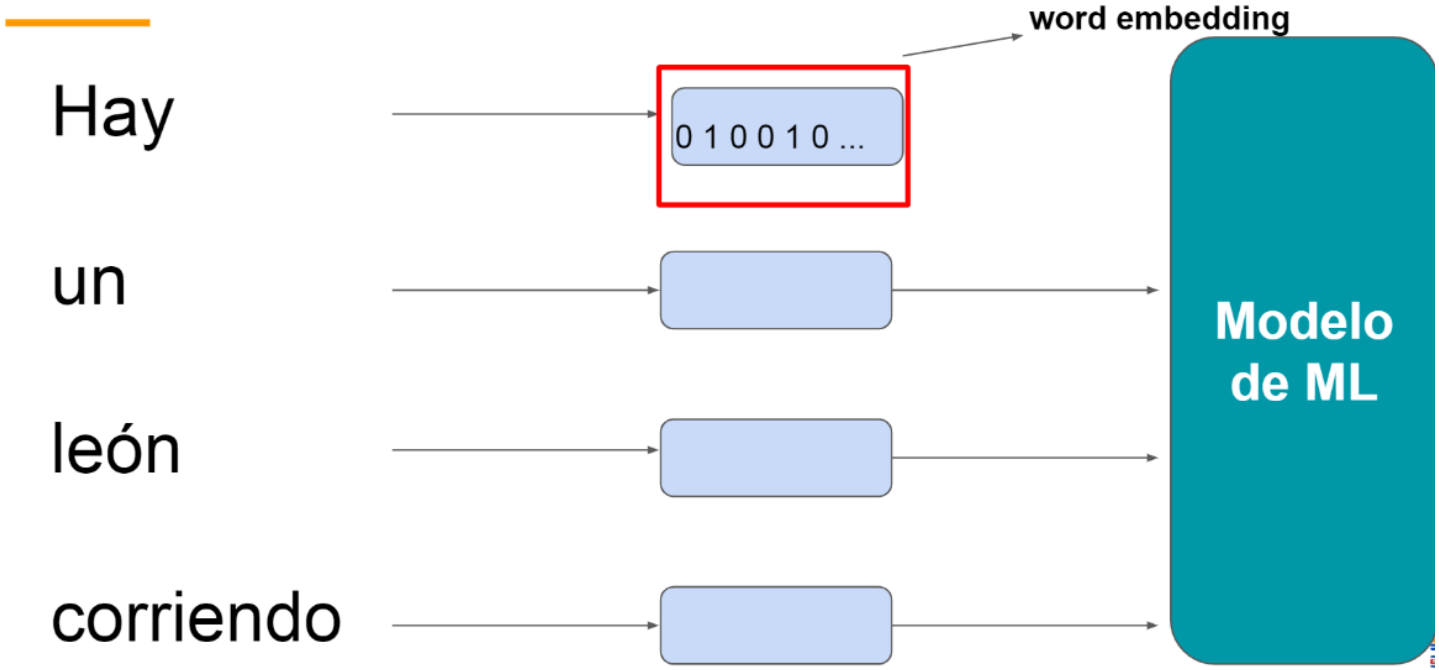
word embedding
Hay
un
león
corriendo
0 1 0 0 1 0 ...
Modelo de ML

Tokenización + Vectorización

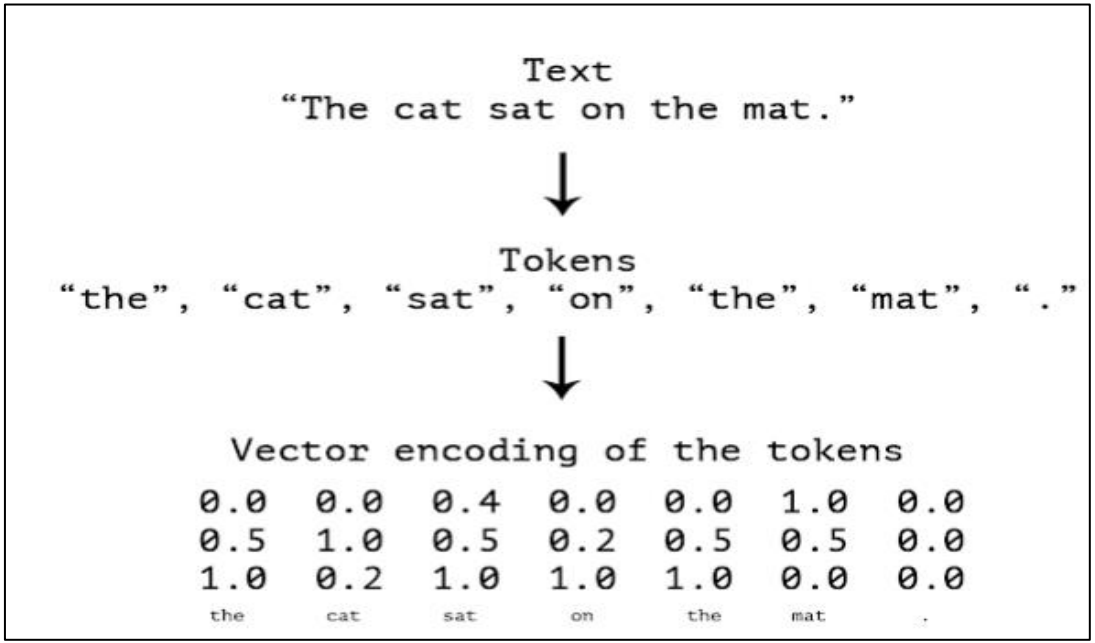

Vectorización

¿Cómo asignamos un vector a un token?

- One-hot encoding
- Embedding

One-hot encoding

1. A cada token del vocabulario se le asigna un id (entero)
2. Se construye vector binario:
   - ✚ Vector tiene tamaño N, donde N es el número de tokens del vocabulario
   - ✚ Vector consta de todo 0s salvo un 1 en la posición id

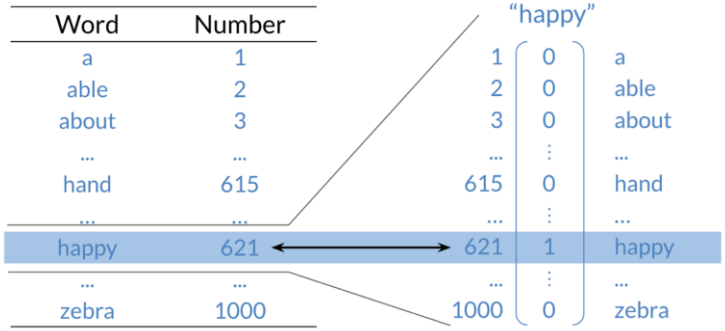

Country
India
Australia
Russia
America

Country	India	Australia	Russia	America
India	1	0	0	0
Australia	0	1	0	0
Russia	0	0	1	0
America	0	0	0	1

Sol [0, 1, 0, 0]
Playa [0, 0, 1, 0]
Hola [1, 0,0,0]
Feliz [0, 0, 0, 1]

Vocabulario: Hola, Sol, Playa

One-hot encoding

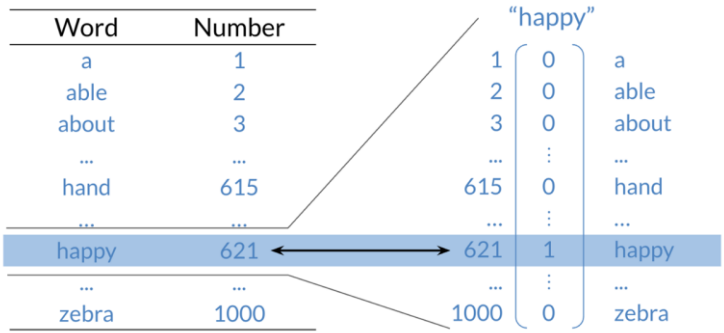

Problemas:

- Altas dimensiones para los vectores
- No hay relación entre las palabras

Representando palabras por su contexto

Hipótesis de distribución:

- *"You shall know by the company it keeps" [J. R. Firth (1957)]*
- *"Dime con quien andas y te dire quien eres"*
- Las palabras que ocurren en contextos similares tienden a tener significados similares

Distribución semántica

¿Qué significa gazpiña?

Distribución semántica

Vamos a ver cómo se usa *gazpiña* en distintos contextos:

- Hay una jarra de gazpiña en el frigorífico
- A todo el mundo le gusta la gazpiña
- La gazpiña no me sentó bien y acabé borracho
- La gazpiña es muy azucarada

Distribución semántica

¿Qué puede significar *gazpiña*?

Distribución semántica

¿Qué puede significar *gazpiña*?

La *gazpiña* podría ser una bebida alcohólica y azucarada

¿Como llegamos a esa conclusión?

Distribución semántica

¿Qué otras palabras encajan?

- Hay una jarra de [redacted] en el frigorífico
- A todo el mundo le gusta la [redacted]
- La [redacted] no me sentó bien y acabé borracho
- La [redacted] es muy azucarada

Distribución semántica

¿Qué otras palabras encajan?

- Hay una jarra de [redacted] en el frigorífico
- A todo el mundo le gusta la [redacted]
- La [redacted] no me sentó bien y acabé borracho
- La [redacted] es muy azucarada

	(1)	(2)	(3)	(4)
Gazpiña	1	1	1	1
Música	0	1	0	1
Basura	0	0	0	0
Cerveza	1	1	1	0
Sangria	1	1	1	1

Distribución semántica

Las palabras que aparecen de manera frecuente en contextos similares tienen un significado similar

Palabras como vectores

Construimos un modelo de significado basado en la similitud:

- Cada palabra es un vector
- Las palabras similares están cerca en el espacio

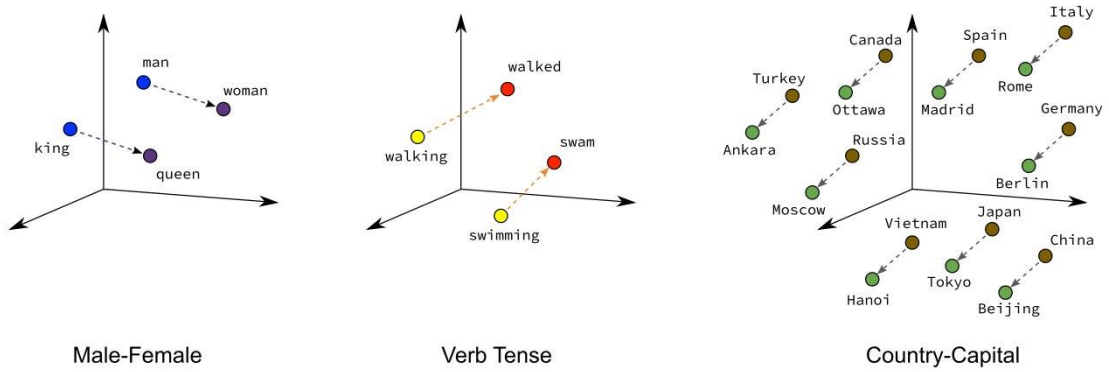

Una primera solución

Usar vectores de contexto para representar palabras

Matriz de co-ocurrencia palabra-a-palabra:

	aardvark	computer	data	pinch	result	sugar	...
apricot	0	0	0	1	0	1	
pineapple	0	0	0	1	0	1	
digital	0	2	1	0	1	0	
information	0	1	6	0	4	0	

Similitud

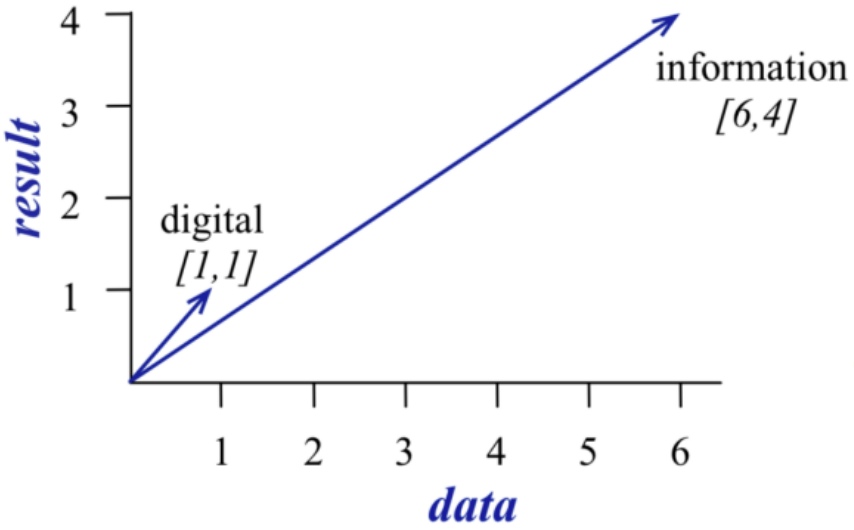

$$cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|\|\mathbf{v}\|}$$

$$cos(\mathbf{u}, \mathbf{v}) = \frac{\sum_{i=1}^{V} u_i v_i}{\sqrt{\sum_{i=1}^{V} u_i^2}\sqrt{\sum_{i=1}^{V} v_i^2}}$$

Similitud (ejemplo)

	Vuelo	Animal	Casa
Perro	0	4	5
Gato	0	5	4
Avión	5	1	0

$$cos(perro, gato) = \frac{0 * 0 + 4 * 5 + 5 * 4}{\sqrt{0^2 + 4^2 + 5^2}\sqrt{0^2 + 5^2 + 4^2}} = 0.97$$

$$cos(perro, avion) = \frac{0 * 5 + 4 * 1 + 5 * 0}{\sqrt{0^2 + 4^2 + 5^2}\sqrt{5^2 + 1^2 + 0^2}} = 0.12$$

PPIM

Problema:

- No todos los conteos son iguales
- Palabras pueden ocurrir de forma aleatoria

Solución:

- PPIM (Positive Pointwise Mutual Information)

$$PPMI(w,c) = max(log_2 \frac{P(w,c)}{P(w)P(c)}, 0)$$

Que ocurre con la representacion basada en ocurrencias?

- A pesar de que las palabras tienen relacion

- Vectores son dispersos (mayoría 0s) y largos
- Nos gustaría vectores cortos (50-300) y densos.

Vectores densos

- Vectores cortos son más fáciles de usar en aprendizaje automático
- Generalizan mejor que simplemente contar
- Capturar mejor las relaciones
  - w1 co-ocurre con coche, w1 co-ocurre con automóvil

Aprendiendo embeddings

Buen embedding depende del problema

Mejor embedding para tarea de analizar valoraciones será distinto al mejor embedding para clasificar textos legales

Embeddings pre-aprendidos

¿Qué ocurre si tenemos pocos datos?

- Utilizar embedding genérico
- Word2Vec, GloVe, FastText

Word2vec

Skipgram

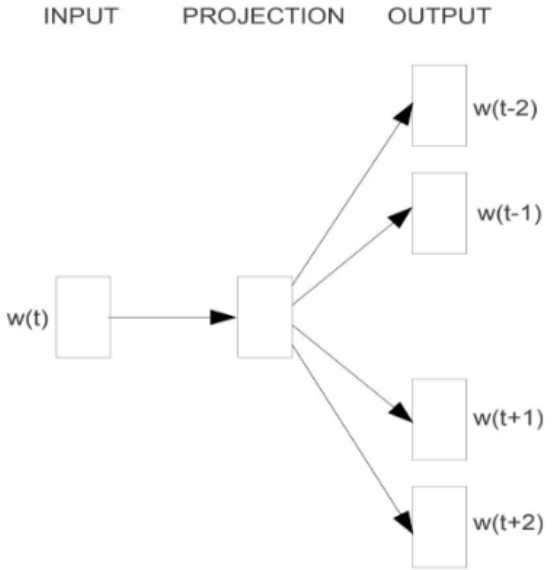

predice el contexto dada una palabra central

CBOW

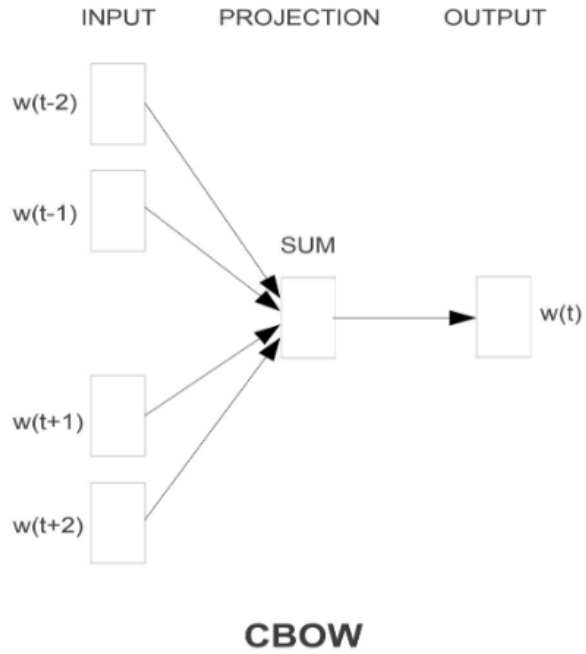

predice la palabra central sumando los vectores de contexto

Modelo CBOW

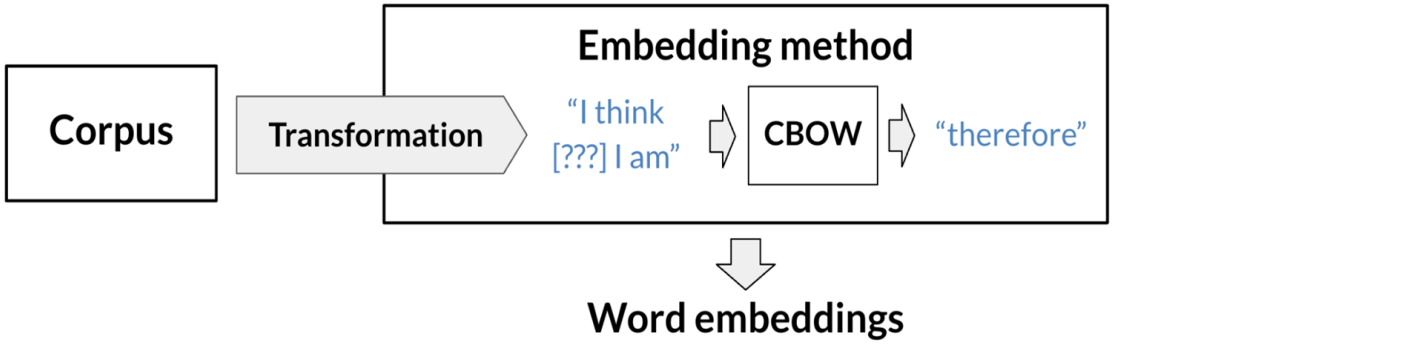
Corpus
Transformation
Embedding method
"I think [???] I am"
CBOW
"therefore"
Word embeddings

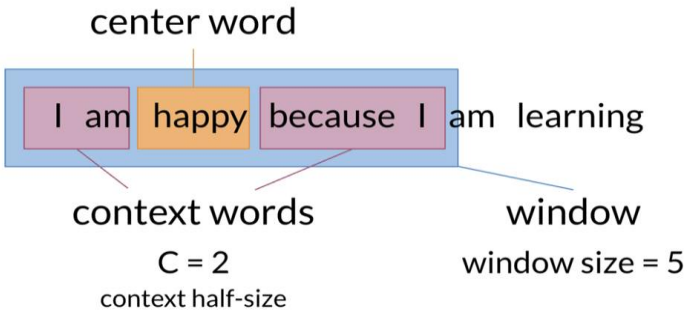
center word
I am happy because I am learning
context words
C = 2
context half-size
window
window size = 5

Modelo CBOW

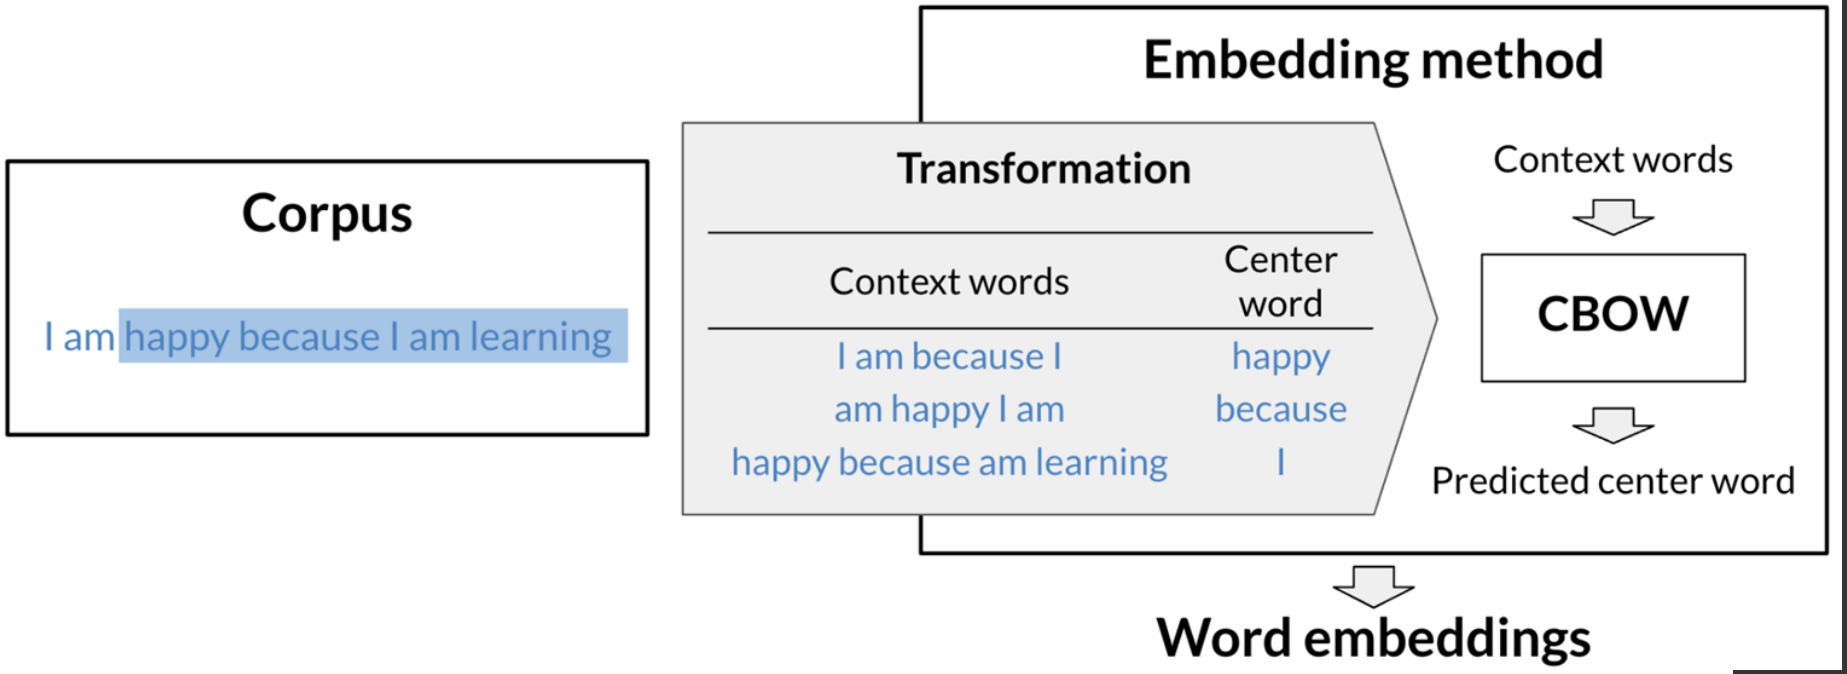
Corpus
I am happy because I am learning
Embedding method
Transformation
Context words
Center word
I am because I
happy
am happy I am
because
happy because am learning
I
Context words
CBOW
Predicted center word
Word embeddings

Glove

- Matriz de co-ocurrencias
  - ✕ Derivamos la relacion semantica entre las palabras
- Factorización de Matrices para reducir la dimensión de la matriz de co-ocurrencia
  - ✚ Representaciones más compactas y significativas para cada palabra
- Vectores de Palabras

FastText

- Extensión de word2vec
- En lugar de usar palabras se usan n-gramas
- La palabra “artificial” con n=3 se divide en:
  - <ar, art, rti, tif, ifi, fic, ici, cia, ial, al>

Espacio semántico

Conjunto de embeddings representados en el espacio forman un espacio semántico

https://lena-voita.github.io/nlp_course/word_embeddings.html#analysis_interpretability

Vecinos más cercanos

Closest to **frog**:

frogs
toad
litoria
leptodactylidae
rana
lizard
eleutherodactylus

litoria

leptodactylidae

rana

eleutherodactylus

Similitud de palabras

Rare words similarity benchmark

word pair		score
vulgarism	profanity	9.62
subdividing	separate	8.67
friendships	brotherhood	7.5
exceedance	probability	5.0
assigned	allow	3.5
marginalize	interact	2.5
misleading	beat	1.25
radiators	beginning	0

Relación lineal

semantic: $v(\text{king}) - v(\text{man}) + v(\text{woman}) \approx v(\text{queen})$

syntactic: $v(\text{kings}) - v(\text{king}) + v(\text{queen}) \approx v(\text{queens})$

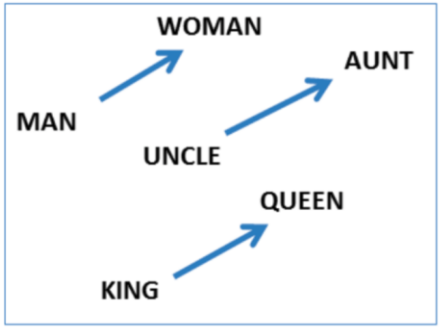

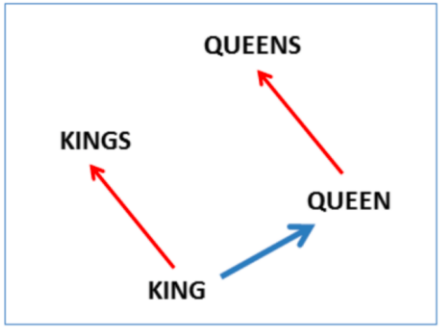

Analogías

Analogía: **a** es a **a*** como **b** es a _____

Tarea: v(a*)-v(a)+v(b) ≈ ?

relation	word pair 1		word pair 2	
man-woman	brother	sister	grandson	granddaughter
currency	Angola	kwanza	Iran	rial
opposite	possibly	impossibly	ethical	unethical
past tense	walking	walked	swimming	swam
superlative	easy	esiest	lucky	luckiest

Índice

REPRESENTACIÓN DE TEXTOS

USO EN MODELOS DE APRENDIZAJE AUTOMÁTICO

Clasificación de texto

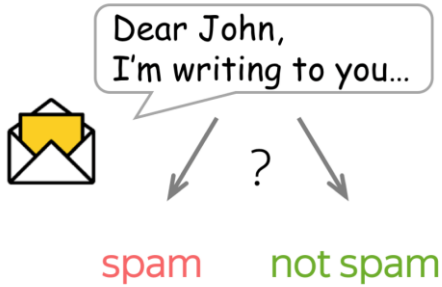

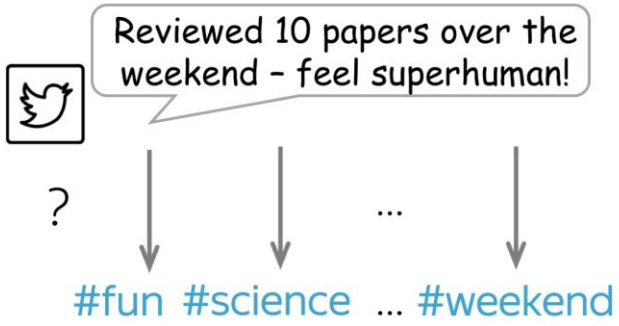

Clasificación de texto

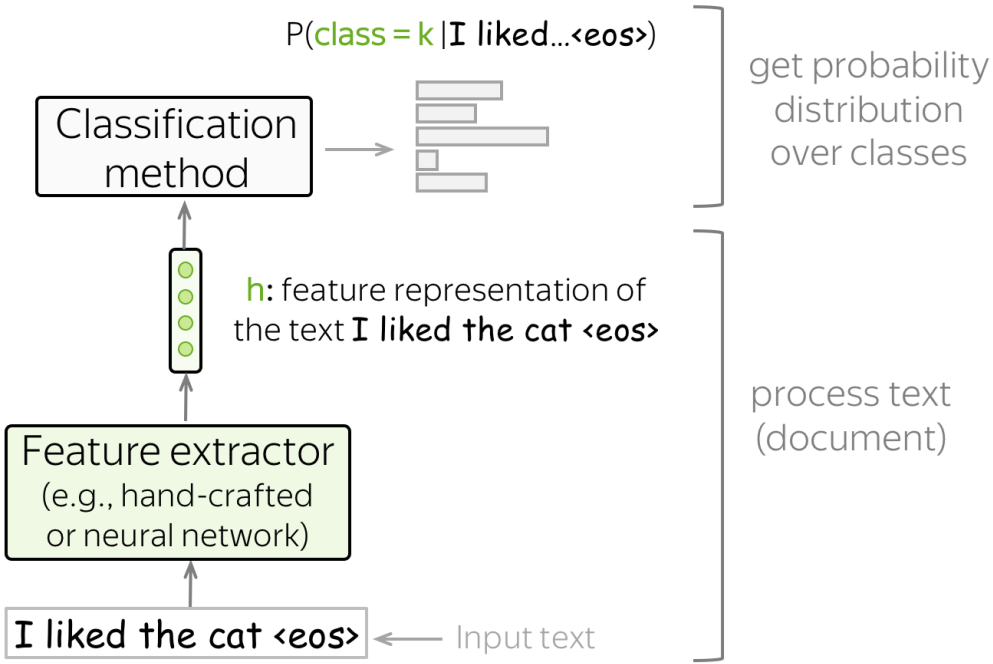

Bolsa de palabras (bag of words)

Frecuencia de palabras en cada frase

```
messages = ["Hey hey hey lets go get lunch today :)",
            "Did you go home?",
            "Hey!!! I need a favor"]
```

	did	favor	get	go	hey	home	lets	lunch	need	today	you
0	0	0	1	1	3	0	1	1	0	1	0
1	1	0	0	1	0	1	0	0	0	0	1
2	0	1	0	0	1	0	0	0	1	0	0

Bolsa de palabras

Palabras muy comunes tienen mucha más importancia que palabras “raras”

TF-IDF

Frecuencia de términos (*term frequency, tf)*

Frecuencia inversa de documentos (*inverse document frequency, idf)*

TF-IDF:

$$\mathrm{tfidf}(t, d, D) = \mathrm{tf}(t, d) \cdot \mathrm{idf}(t, D)$$

TF-IDF

2 cálculos:

- A través de TF (Term Frequency / Frecuencia de término) se calcula la frecuencia relativa de una palabra en un documento entre el número total de palabras del documento.
- Con IDF se calcula la frecuencia inversa de documento (Inverse Document Frequency) dividiendo el número total de documentos entre el número de documentos que contienen el término.

De esta manera, mediante TF-IDF es posible el cálculo de la relevancia y de los pesos de los términos en los documentos

Limitaciones

- Dimensión muy grande
- No tienen en cuenta el orden
- Vectores sparse

Embeddings

- Embeddings dan representación compacta
- Algoritmos de ML necesitan un vector, pero las frases tienen distinta longitud
- No sirve con concatenar los vectores

Bolsa de embeddings (bag of embeddings)

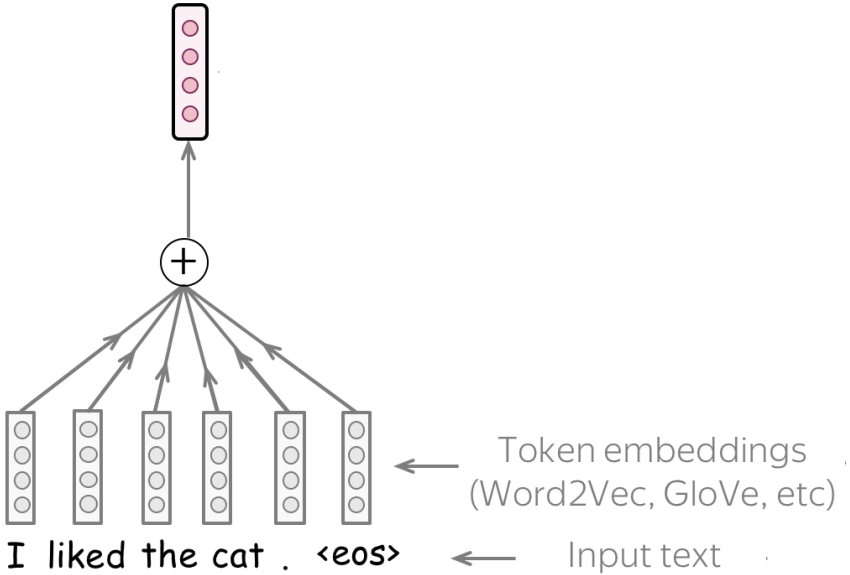

Bolsa de embeddings con peso

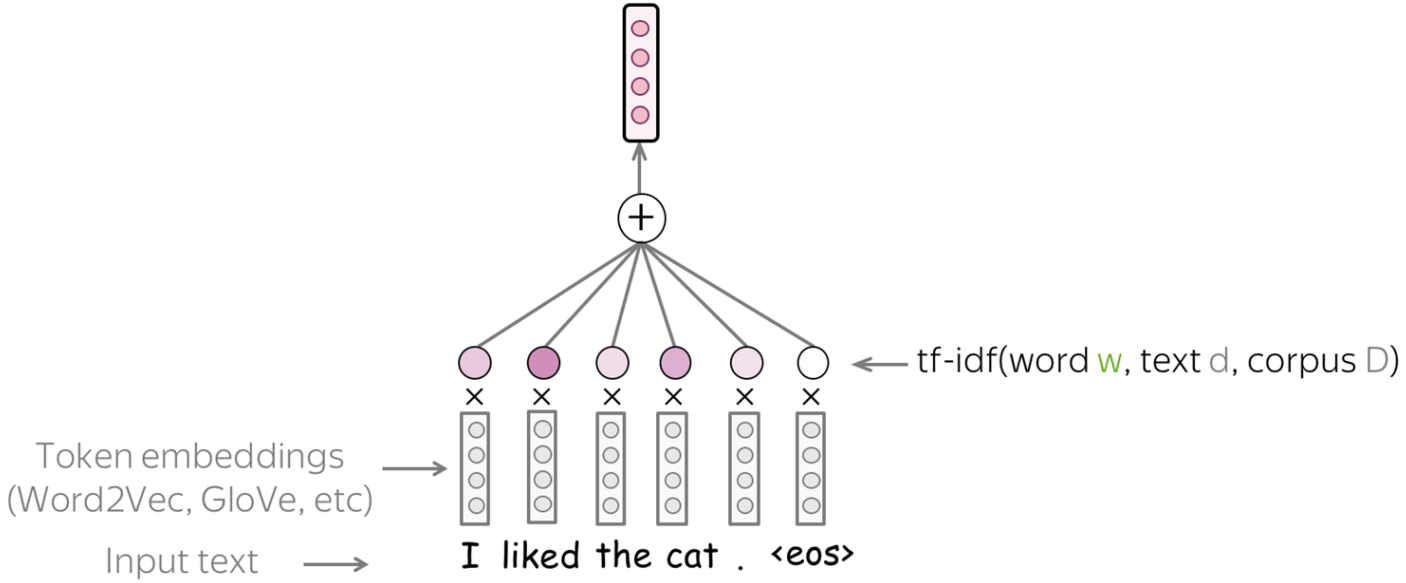

Métodos de clasificación

Los ya conocidos:

- SVM
- KNN
- Redes neuronales
- Árboles de decisión
- …

Bolsa de embeddings con peso

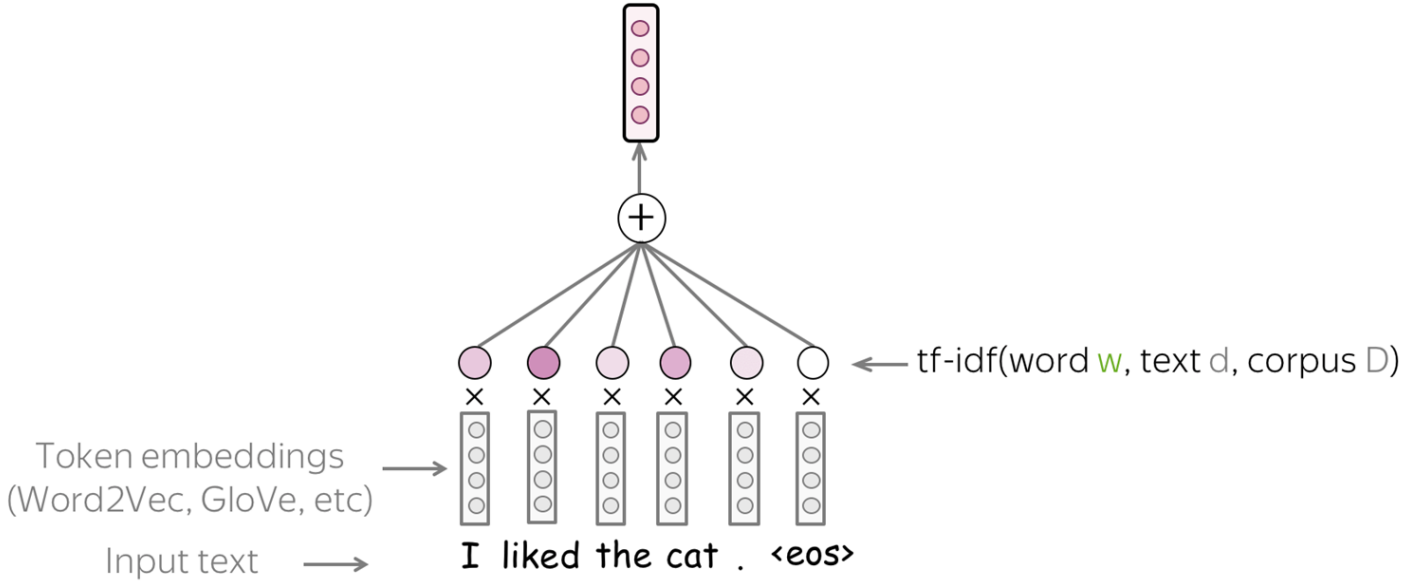

Vectorización de textos